

TWO-DEVELOPER TASK SPLIT · 双人开发计划

Specter两人开发计划v2

把project_plan_v9.md单人27-28天路线图拆成两条并行轨道—— developer A / developer B的任务认领、并行窗口与里程碑判据

版本

v2（草稿，待challenge review）

日期

2026-08-27

状态

已开PR #2（分支add-two-dev-task-plan），未合并

来源

project_plan_v9.md §7/§11/§16任务级依赖拆分

§0 / WHAT CHANGED IN V2

v2相比v1改了什么

针对用户两条challenge的具体修正——v1把P4/P5.2/P5.4整体标成“联合任务”，掩盖了它们内部其实能再拆出并行子任务；v1的里程碑只有一张模糊的ASCII时间线。

你的challenge	v1的问题	v2的修正
“没看到哪里能并行”	v1把P4、P5.2、P5.4直接标“联合任务”，掩盖了各自内部其实有能拆开独立执行的子任务	§2/§3拆到子任务粒度：P4拆成“投机解码曲线”vs“量化曲线”两条独立曲线；P5.2拆成AWQ臂vs BnB臂；P5.4拆成HF基线vs BanditSpec基线——每一对都能两人同时做，只在最后合并结果
“milestone没写详细”	v1只有一张模糊的ASCII时间线	§4换成里程碑表：每个里程碑标Day数、交付物、验收标准、负责人、前置依赖

§1 / STATUS

现状评估（沿用v1，未改动实质内容）

1.1计划本身

project_plan_v9.md已过架构可行性评审（v9），9个关键决策点已落定为ADR（contracts/decisions/）。按§17，正式进入阶段0仍需用户明确授权——两人协作下变成“两人都要认可”。

1.2代码现状（会改变排期起点）

Michael8964/Specter目前只有骨架+待合并的PR #1（notes/papers迁移）。但本地已有跑通的P1.0结果，还没进任何仓库：

文件	内容
src/gate_p1_0.py（206行）	HF Transformers实现的P1.0 gate
src/gate_p1_0_mlx_crosscheck.py（124行）	mlx-lm交叉验证
src/results/p1_0_gate_result.json	draft=Qwen2.5-0.5B / target=Qwen2.5-3B，vocab_match=true，overall_alpha=0.7024（PASS）
src/results/p1_0_mlx_crosscheck_result.json	overall_alpha=0.5591，同量级

阶段0实质已完成

只差迁移+第二人复核。建议排期从“迁移+联合复核（0.5天）”开始，而不是从零开始的P1.1。

§2 / TASK-LEVEL DEPENDENCIES

任务级依赖关系

之前v1只分析到“支柱”层级，容易把内部可拆分的任务误判成不可拆。这次逐个P-子任务核对依赖：

子任务	实际输入	是否需要另一方产出	判断依据（引用§7原文）
P1.1-P1.4	draft/target模型	否	“标准算法：草稿模型自回归生成Y个候选…目标模型单次前向打分”——纯双模型循环，不涉及量化或评测框架

子任务	实际输入	是否需要另一方产出	判断依据（引用\$7原文）
P2.0-P2.3	target模型+校准集	否	“在校准集上跑前向，收集每层激活值的逐通道统计量”——不涉及投机解码循环
P2.4（Mac）	target模型	否	mlx_lm.awq是独立工具链，“额外可产出真实的Mac端AWQ速度/内存数字”
P3.0	无（设计阶段）	否	“15-20个bash/工具调用任务，改编自AgentBench OS子环境”——任务清单设计不需要跑引擎
P3.1	P1的可运行引擎	是（需A）	“同一模型对，工具调用/结构化输出场景vs自由文本对话场景，对比a差异”——a测量必须有能跑的投机解码
P5.0-P5.1	P1的可运行引擎	是（需A自己产出，非B）	“接受数A与当前γ相等时扩窗”——直接操作P1循环内部状态，不需要B的量化产出
P5.3	P1+P5.0的产出	是（需A自己产出）	“高batch时自动降级/禁用投机解码”——建立在P5.0的γ控制逻辑上
P4投机解码曲线	P1的引擎	是（需A）	\$7 P4.0 “投机解码…各测一条吞吐提升曲线”——这一条曲线只需要P1，不需要量化模型
P4量化曲线	P1的引擎+ B的AWQ模型	是（需A的引擎+B自己的模型）	同上，“量化…测一条吞吐提升曲线”——这一条曲线B可以独立跑，只是需要A的引擎已经存在（不需要A本人参与）
P5.2 AWQ臂	P5.0的控制器代码+ B的AWQ模型	需要A已完成的控制器代码（不需要A本人同时在场）	\$7 P5.2 “复用P2的量化模型…对同一draft/target组合分别扫描最优γ”
P5.2 BnB臂	P5.0的控制器代码+ BnB配置（HF内置）	同上	ADR-008：“几乎零成本（HF内置配置）”
P5.4 HF双基线	A已有的测试harness	否（A独立可做）	“HF Transformers num_assistant_tokens_schedule/assistant_confidence_threshold”——都是配置项，A的现有代码改几行配置
P5.4 BanditSpec基线	无（独立代码库）	否（B独立可做）	“BanditSpec公开代码…直接克隆运行”——完全独立的第三方代码库，不需要A的产出

关键结论（回应你的第一条challenge）

真正意义上“必须两人同时坐在一起改同一段代码”的任务其实不存在。所谓“联合任务”绝大部分是“两人各自独立产出一部分，最后合并对比”——这是可以并行的，只是需要一个共享的前置产出（比如“A把P1引擎跑通”）作为解锁条件，而不是全程绑在一起。唯一真正需要坐在一起讨论的是“合并/对比结果”那一步（找batch交叉点、对比γ偏移量级），这一步天然很短（通常<1天）。

§ 3 / PARALLEL WINDOWS

并行窗口一览表

窗口	Day范围（估计）	A在做什么	B在做什么	是否真并行	解锁条件/备注
W0	Day 0-0.5	联合复核P1.0已有结果	同左	联合（非并行，但只需0.5天）	见§1.2
W1	Day 0.5-6	P1.1-P1.4（核心投机解码，7天中的前5.5天）	P2.0-P2.3（全部5.5天）	真并行	互不依赖（§2）
W2	Day 6-7.5	继续P1.1-P1.4（还剩1.5天）	空档→P2.4-Mac交叉验证（1d）+P3.0任务设计启动（0.5d）	B独立填充，不算联合	P2.4/P3.0设计都不需要A
W3	Day 7.5-10	P5.0-P5.1（3天，只需P1，不需要B）	P3.0收尾（1.5d）+P3.1（1d）	真并行	A解锁条件是“自己的P1完成”；B解锁条件是“A的引擎存在”，两人此后各自独立推进
W4	Day 10-10.5	继续P5.0-P5.1	空档（0.5d）→提前写P4量化曲线的脚本	B独立填充	不需要A参与
W5	Day 10.5-12.5	P5.3（2天，只需P5.0，不需要B）	P4量化曲线（1d）+云端P2.4的本地dry-run脚本准备（1d，§10要求）	真并行	两人各自独立产出，互不阻塞
W6	Day 12.5-13.5	P4投机解码曲线（1天，只需自己的P1引擎）	（已在W5提前完成量化曲线，此时空档或帮A做数据整理）	部分并行	A是这个窗口唯一的阻塞方
W7	Day 13.5-14	联合：合并两条batch曲线找交叉点，写P4.1记录	同左	联合（0.5天）	唯一必须“坐在一起”的环节之一
W8	Day 14-14.5	联合：云端启动会（预算记账方式、GPU实例数量决策——见§5）	同左	联合（0.5天）	决策点，非执行
W9	Day 14.5-16.5（若2个GPU实例）	P5.4 HF双基线（1d）+P4.2投机解码曲线（1d）	P2.4云端GPTQ速度（1d）+P4.2量化曲线（1d）	真并行（需2个GPU实例，见§5）	若只租1个实例，这一列变成排队执行，见§5
W10	Day 16.5-18（若2个GPU实例）	P5.2 AWQ臂（1d）	P5.2 BnB臂（0.5d）+P5.4 BanditSpec基线（1d）	真并行（同上前提）	
W11	Day 18-19	联合：合并P4.2曲线+P5.2两臂结果+held-out集最终跑一次	同左	联合（1天）	计划要求held-out只跑一次（\$9.6风险1），必须两人都在场确认这是“唯一一次”
W12	Day 19-21	联合：README+简历bullet（阶段7）	同左	联合（2天）	

并行窗口小计

W1/W3/W5/W6/W9/W10六个窗口是两人各自做不同事情、互不等待的真并行区间，覆盖了从Day 0.5到Day 18里的大部分时间；真正“必须两人一起做同一件事”的只有W0、W7、W8、W11、W12，加起来约4.5天。

总工期估计

约19-21天（云端若租2个GPU实例；若只租1个，见\$5，云端阶段拉长约1.5-2天，总工期约21-23天）。这仍是排期估计，不是承诺值。

§ 4 / MILESTONES

里程碑表

里程碑	预计完成日	交付物	验收标准（对应\$11完成判据）	负责人	前置依赖
M0	Day 0.5	P1.0结果迁移进 Michael8964/Specter + 双人复核记录	两人都读过gate_p1_0.py核心逻辑，无异议	A+B联合	无
M1	Day 6	P2.0-P2.3完成	perplexity涨幅数字产出；跨分布矩阵产出；校准集消融产出（\$11阶段2）	B	M0
M2	Day 7.5	P1.1-P1.4完成	贪心100%一致；采样 α 与理论公式吻合；bonus token测试通过；验证器故障注入测试通过； γ 扫描曲线产出（\$11阶段1）	A	M0
M3	Day 10	P3.0-P3.1完成	15-20任务跑通（含3-5个held-out）；结构化vs自由文本 α 对比数字产出（\$11阶段3）	B	M2
M4	Day 12.5	P5.0-P5.1-P5.3完成	GammaTune复现论文量级提速（3次跑均值±标准差）；波动场景测试产出；熔断器重探测机制实现（\$11阶段4）	A	M2
M5	Day 14	P4.0-P4.1完成（Mac部分双曲线已合并）	交叉点初步曲线产出；显存占用数据产出；mlx_lm.awq真实Mac AWQ速度数字产出（\$11阶段5）	A+B（各自曲线+联合合并）	M1+M2
M6	Day 14.5	云端启动会纪要（预算记账方式+GPU实例数量决定）	两人书面确认，见\$5	A+B联合	M5
M7	Day 18	P2.4云端补全+P4.2+P5.2（AWQ+BnB双臂）完成	LLM Compressor对比数字；vLLM对比数字；AWQ量化- γ 偏移结论+BnB同源对照结论（\$11阶段6前半）	A+B（各自执行）	M6
M8	Day 19	P5.4三基线对比+held-out最终确认	HF双基线+BanditSpec代码对比数字；held-out集跑一次最终确认（\$11阶段6后半）	A+B联合（合并环节）	M7
M9	Day 21	GitHub repo定稿+README+简历bullet	\$11阶段7完成判据	A+B联合	M8

§ 5 / GPU INSTANCE CONSTRAINT

关键约束：云端阶段的并行程度取决于GPU实例数量

这是v1没有点出的一个硬约束：Mac阶段两人各用自己的Mac，天然物理并行；但云端阶段如果只租一个GPU实例，A和B没法同时用它跑各自的实验——W9/W10里标的“真并行”会退化成排队执行，云端阶段总时长不会缩短，只是两人交替上手。

方案	效果	代价
租1个GPU实例（原计划默认，\$30-50预算按1份算）	云端阶段仍需排队，约4-5天，两人协作只省了“谁先谁后”的调度成本	预算不变
租2个GPU实例（W9/W10表格里假设的情况）	云端阶段真并行，约3天完成	预算翻倍风险——\$5护栏指标的\$50硬顶是按单实例场景定的，两个实例大概率突破\$50

待共同确认

这是计划里完全没写过的新决策点，两人需要自己定——大概率结论应该是租1个实例、接受云端阶段排队执行，因为\$50硬顶（护栏指标）大概率经不起双实例开销；如果要租2个，需要重新和用户确认预算上限是否还是\$50。我不替你们做这个决定，但把两个选项的代价都摆出来了。

§ 6 / TASK CLAIMS

任务认领表（细到子任务，可直接勾选）

P-任务/子任务	内容	建议归属	前置依赖	计划出处
P1.0	前置gate	已完成，待联合复核	无	\$7 P1.0
P1.1-P1.4	投机解码核心+验证	A	P1.0	\$7 P1.1-1.4
P2.0-P2.3	AWQ校准+正确性	B	无	\$7 P2.0-2.3
P2.4 (Mac)	mlx_lm.awq交叉验证	B（可提前）	无	\$7 P2.4
P3.0	AgentBench任务设计	B（可提前）	无	\$7 P3.0
P3.1	接受率对比实验	B	P1.1-1.4	\$7 P3.1
P5.0-P5.1	GammaTune算法+波动测试	A	P1.1-1.4	\$7 P5.0-P5.1
P5.3	Batch-aware熔断器	A	P5.0	\$7 P5.3
P4（投机解码曲线）	batch扫描-非量化侧	A	P1.1-1.4	\$7 P4.0
P4（量化曲线）	batch扫描-量化侧	B	P1.1-1.4 + P2.1	\$7 P4.0
P4.1	显存占用记录	A+B各记自己那条曲线	同上	\$7 P4.1
P4（合并）	找交叉点，联合写记录	联合	P4两条曲线都完成	\$7 P4.0-4.1

P2.4（云端）	LLM Compressor GPTQ速度	B	P2.1	§7 P2.4
P4.2（投机解码曲线，云端）	大模型batch验证-非量化侧	A	P4（合并）	§7 P4.2
P4.2（量化曲线，云端）	大模型batch验证-量化侧	B	P4（合并）	§7 P4.2
P5.2（AWQ臂）	量化-γ耦合，AWQ侧	A（用自己的控制器）+B的AWQ模型	P5.0 + P2.1	§7 P5.2
P5.2（BnB臂）	量化-γ耦合，BnB对照	B（HF配置）+A的控制器代码	P5.0 + ADR-008	§7 P5.2
P5.4（HF双基线）	HF内置两种基线对比	A	P5.0-5.3	§7 P5.4
P5.4（BanditSpec基线）	克隆跑第三方代码	B	无（独立代码库）	§7 P5.4
held-out最终跑一次	全部超参数定稿后跑一次	联合（必须双人见证，§9.6风险1）	所有超参数定稿	§9.6风险1
阶段7产出	README+简历bullet	联合	全部完成	§11阶段7

§7 / COLLABORATION DISCIPLINE

协作纪律（沿用v1，未改动）

- 1.接口边界：B的AWQ模型要能被A的引擎直接加载，建议两条轨道各自进行到一半时（约Day3-4）先对一次接口形状。待共同确认：具体接口形式计划里没写。
- 2.云端预算记账：见§5，现在多了“租几个实例”这个新决策，\$50硬顶怎么在双实例场景下重新界定，待共同确认。
- 3. Git工作流：延续直接在Michael8964/Specter开分支+PR、不fork的模式。待共同确认：分支命名约定（建议a/、b/前缀）。
- 4. P1.0复核不能省：进入P1.1前，B至少读一遍gate_p1_0.py核心逻辑，确认没有假阳性风险（contracts/research-integrity.md风险3的精神）。

§8 / OPEN QUESTIONS

开放问题

- 1. project_plan_v9.md §16原有5条开放问题依然成立，现在需两人共同决定。
- 2.云端GPU实例数量（§5，v2新增，最重要的一条新开放问题）。
- 3.云端账号/计费主体由谁持有，如何同步进度。
- 4. contracts/里的ADR/坑表是单人视角写的，两人协作后谁负责在跨轨道决策变化时同步更新（比如中途换draft/target模型对）。

§9 / VERSION LOG

版本记录

v1
基于project_plan_v9.md依赖图拆两轨道，发现本地已有P1.0结果未纳入排期，计入§1.2；但把P4/P5.2/P5.4整体标“联合任务”，掩盖了内部并行空间。

v2（本版本）
针对“没看到哪里能并行”的challenge，把P4/P5.2/P5.4拆到子任务粒度，识别出6个真并行窗口（§3）；针对

“milestone不详细”的challenge，新增里程碑表（§4）；新发现一个v1完全没提过的约束——云端阶段的并行程度取决于GPU实例数量，且直接牵动\$50预算护栏（§5）。等待下一轮challengereview。